

SISTEMATIZAÇÃO

Laboratório Estatístico Interativo

Estatística implementada do zero sobre 6.427 corridas de táxi de Nova York

Matemática e Estatística para Computação

Prof. Romes Heriberto

Integrante(s)

João Gabriel Amaral de Sales — matrícula 72650411

Item	Link
Fonte original do dataset (NYC TLC)	https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page
Arquivo CSV utilizado	https://raw.githubusercontent.com/mwaskom/seaborn-data/master/taxis.csv
Repositório público (código completo)	https://github.com/Joao-G14/Laboratorio-estatistico
Vídeo de demonstração (3-5 min)	[PREENCHER: LINK DO VÍDEO]

1. Resumo executivo

Construímos uma biblioteca estatística em Python puro (`minhastats.py`) — sem NumPy, SciPy ou `statistics` — e uma aplicação Streamlit de sete módulos que a usa para analisar **6.427 corridas de táxi da cidade de Nova York**, registradas pela NYC Taxi & Limousine Commission entre 28/02/2019 e 31/03/2019.

As 24 medidas do núcleo foram validadas contra NumPy/SciPy com diferença máxima de **$4,09 \times 10^{-12}$** — resíduo de ponto flutuante, não erro de fórmula. A suíte tem **104 testes automatizados** (94 do núcleo, 10 da interface), todos passando.

Os sete módulos

Módulo	O que a aplicação entrega
0 — Dados reais	Fonte, verificação automática dos critérios, dicionário das 13 variáveis, decisões de tratamento e prévia.
1 — Núcleo estatístico	Fórmulas implementadas e tabela de validação ao vivo contra NumPy/SciPy, com diferença e tolerância.
2 — Descritiva interativa	Tendência central, dispersão e posição; tabela de frequências de Sturges; histograma; boxplot com outliers do IQR; barras/pizza; interpretação textual automática.
3 — Simulação	Lei dos Grandes Números (moeda/dado) e Teorema Central do Limite sobre os nossos dados, com controles de repetições e tamanho de amostra.
4 — Distribuições teóricas	Normal e Exponencial/Uniforme sobre o histograma em densidade; Poisson para a contagem de passageiros; erro de ajuste medido.
5 — Correlação e regressão	Dispersão, r de Pearson, mínimos quadrados, R^2 , resíduos e predição interativa com alerta de extrapolação.
6 — Descobertas	As três descobertas com evidência e limite honesto, mais as limitações gerais da análise.

As três descobertas

- 1. Quem paga em dinheiro nunca dá gorjeta — e o defeito é do instrumento, não do passageiro.** 100,0% das 1.810 corridas em espécie registram gorjeta exatamente zero, porque o taxímetro só captura gorjeta eletrônica. O zero significa “*não medido*”, não “*não pago*”.
- 2. O número de passageiros não explica nada do preço:** $r = 0,0078$ com a tarifa e $R^2 = 0,000061$. A tarifa em Nova York é do veículo, não da cabeça — os passageiros extras viajam de graça.
- 3. Os outliers de preço têm endereço:** 55,8% das 599 corridas marcadas como outliers pela regra do IQR começam ou terminam em um aeroporto, contra 6,3% no dataset inteiro — concentração 8,8 vezes maior.

A relação central do dataset, usada como fio condutor: a distância explica 85,13% da variação da tarifa ($r = 0,9227$), pela reta $\hat{y} = 2,7791 \cdot x + 4,6738$.

2. O conjunto de dados

2.1 De onde vêm os dados

Os registros são das corridas de táxi da cidade de Nova York, coletados e publicados como dado aberto pela **New York City Taxi & Limousine Commission (TLC)**, a autarquia municipal que regula o serviço. A TLC publica os *TLC Trip Record Data* mês a mês: um registro por corrida, gerado pelo próprio taxímetro. Essa é a base primária.

O arquivo que baixamos é uma **amostra consolidada em CSV**, distribuída no repositório público `seaborn-data`, escolhida por ser diretamente reprodutível: uma URL única, sem cadastro, sem chave de API e sem etapa de conversão de Parquet. A cópia exata usada pela aplicação está versionada em `dados/dataset.csv`, de modo que qualquer pessoa que clone o repositório reproduz os mesmos números.

Item	Valor
Fonte original (órgão)	https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page
Arquivo CSV baixado	https://raw.githubusercontent.com/mwaskom/seaborn-data/master/taxis.csv
Período coberto	28/02/2019 a 31/03/2019
Registros	6.433 no arquivo → 6.427 após o tratamento
Variáveis	6 numéricas + 1 derivada · 6 categóricas

2.2 Por que escolhemos este dataset

Além de atender com folga aos critérios da atividade, o táxi é um serviço que qualquer pessoa entende — o que permitiu formular perguntas de verdade antes de olhar os números, em vez de apenas descrever colunas. E a estrutura estatística é rica: variáveis fortemente assimétricas (material ideal para o Teorema Central do Limite), uma relação linear quase de livro-texto (distância × tarifa, $r = 0,92$) e armadilhas reais de medição — que acabaram virando a descoberta mais interessante do trabalho.

2.3 As variáveis

Coluna	Tipo	Significado
<code>distance</code>	numérica contínua	Distância percorrida, medida pelo taxímetro.
<code>fare</code>	numérica contínua	Valor do taxímetro, antes de gorjeta e pedágios.
<code>tip</code>	numérica contínua	Gorjeta registrada (ver descoberta 1).
<code>tolls</code>	numérica contínua	Pedágios de pontes e túneis repassados.
<code>total</code>	numérica contínua	Tarifa + gorjeta + pedágios + taxas.
<code>passengers</code>	numérica discreta	Número informado pelo motorista.
<code>duracao_min</code>	numérica contínua (derivada)	Minutos entre embarque e desembarque.
<code>color</code>	categórica nominal	yellow (toda a cidade) ou green (fora do centro).
<code>payment</code>	categórica nominal	credit card ou cash.
<code>pickup_borough</code>	categórica nominal	Manhattan, Queens, Brooklyn, Bronx.
<code>dropoff_borough</code>	categórica nominal	Inclui Staten Island.

Coluna	Tipo	Significado
pickup_zone	categórica nominal	Zona tarifária de origem (194 níveis).
dropoff_zone	categórica nominal	Zona tarifária de destino (203 níveis).

2.4 Decisões de tratamento

1. Conversão de data/hora e coluna derivada. pickup e dropoff viraram *datetime*, e deles derivamos *duracao_min*. É a única coluna que criamos.

2. Remoção de 6 corridas com duração ≤ 0 . Uma corrida que termina antes de começar é fisicamente impossível: é erro de taxímetro, não dado. Restaram 6.427 registros dos 6.433 originais (0,09% descartado).

3. Ausentes categóricos viraram categoria. As colunas *payment* (43 linhas), *pickup_zone* e *pickup_borough* (22), *dropoff_zone* e *dropoff_borough* (39) tinham ausentes — no máximo 0,7% das linhas. Em vez de descartar a corrida inteira, preenchemos com a categoria explícita **“Não informado”**. As colunas numéricas dessas corridas estão completas e são válidas; jogá-las fora perderia informação boa por causa de um campo ruim. E, como a categoria é explícita, ela aparece nas tabelas de frequência em vez de sumir.

4. Mantidas com ressalva: 45 corridas com distância zero e 96 com zero passageiros. Não são impossíveis — provavelmente o motorista não digitou, ou a corrida foi curta demais para o odômetro registrar. Como não temos como distinguir “erro” de “valor real raro”, mantivemos e registramos nas limitações (seção 7).

3. O núcleo estatístico e sua validação

Todas as funções estão em `minhastats.py`, escritas com Python puro e o módulo `math` (apenas `sqrt`, `exp`, `log`, `log10`, `pi`, `lgamma` e `ceil` — funções matemáticas elementares, não estatísticas).

3.1 As fórmulas implementadas

Tendência central e dispersão

$$\bar{x} = (1/n) \cdot \sum x_i \quad s^2 = \sum (x_i - \bar{x})^2 / (n - 1) \quad \sigma^2 = \sum (x_i - \bar{x})^2 / n$$
$$s = \sqrt{s^2} \quad A = x_{\text{máx}} - x_{\text{mín}} \quad CV = (s / \bar{x}) \times 100$$

A correção de Bessel ($n - 1$) existe porque $\bar{x}$ foi estimada dos próprios dados: os desvios em torno dela já são, por construção, os menores possíveis. Dividir por n subestimaria a dispersão da população. No nosso dataset a diferença é pequena mas real — variância do total: 190,4867 (amostral) contra 190,4571 (populacional).

Posição e detecção de outliers

$$\text{posição} = p \cdot (n - 1) / 100 \quad P_p = x[k] + f \cdot (x[k+1] - x[k])$$
$$IQR = Q_3 - Q_1 \quad \text{outlier se } x < Q_1 - 1,5 \cdot IQR \text{ ou } x > Q_3 + 1,5 \cdot IQR$$

k é a parte inteira da posição e f a fracionária. Existem pelo menos nove convenções de percentil; adotamos a interpolação linear, a mesma do método padrão do `numpy.percentile`, para que a validação seja direta e verificável.

Associação, forma e regressão

$$\text{cov}(x,y) = \sum (x_i - \bar{x})(y_i - \bar{y}) / (n - 1) \quad r = \text{cov}(x,y) / (s_x \cdot s_y)$$
$$g_1 = [(1/n) \cdot \sum (x_i - \bar{x})^3] / \sigma^3 \quad S_k = 3 \cdot (\bar{x} - \text{mediana}) / s \quad k = [1 + 3,322 \cdot \log_{10}(n)]$$
$$b_1 = \sum (x_i - \bar{x})(y_i - \bar{y}) / \sum (x_i - \bar{x})^2 = \text{cov}(x,y) / \text{var}(x) \quad b_0 = \bar{y} - b_1 \cdot \bar{x}$$
$$R^2 = 1 - \text{SQ}_{\text{res}} / \text{SQ}_{\text{tot}} = 1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2 \quad s_e = \sqrt{[\sum (y_i - \hat{y}_i)^2 / (n - 2)]}$$

Distribuições teóricas

$$f_{\text{Normal}}(x) = e^{(-1/2 \cdot ((x-\mu)/\sigma)^2)} / (\sigma \sqrt{2\pi}) \quad f_{\text{Exp}}(x) = \lambda \cdot e^{(-\lambda x)}, x \geq 0$$
$$P_{\text{Poisson}}(X=k) = e^{(-\lambda)} \cdot \lambda^k / k! \quad P_{\text{Bin}}(X=k) = C(n,k) \cdot p^k \cdot (1-p)^{(n-k)} \quad f_{\text{Unif}}(x) = 1/(b-a)$$

Poisson e Binomial são calculadas em **escala logarítmica**, com `math.lgamma` no lugar do fatorial: $\log P = -\lambda + k \cdot \log \lambda - \log \Gamma(k+1)$. Com o fatorial direto, k grande estoura o float; em log, não.

3.2 Validação contra NumPy/SciPy

Cada função foi comparada com uma referência independente, sobre as variáveis reais do dataset. Esta tabela é a saída de `python gerar_tabela_validacao.py`.

Função (minhastats.py)	Nosso valor	Referência	Diferença	Tolerância
<code>media(total)</code>	18,51872880	18,51872880	9,95e-13	1e-9
<code>mediana(total)</code>	14,16000000	14,16000000	0,00e+00	1e-9
<code>amplitude(total)</code>	173,52000000	173,52000000	0,00e+00	1e-9
<code>variancia(total, amostral=True)</code>	190,48673130	190,48673130	4,26e-13	1e-9
<code>variancia(total, amostral=False)</code>	190,45709278	190,45709278	4,55e-13	1e-9
<code>desvio_padrao(total, amostral=True)</code>	13,80169306	13,80169306	1,60e-14	1e-9
<code>desvio_padrao(total, amostral=False)</code>	13,80061929	13,80061929	1,60e-14	1e-9
<code>coeficiente_variacao(total)</code>	74,52829623	74,52829623	4,09e-12	1e-9
<code>percentil(total, 25)</code>	10,80000000	10,80000000	0,00e+00	1e-6
<code>percentil(total, 50)</code>	14,16000000	14,16000000	0,00e+00	1e-6
<code>percentil(total, 75)</code>	20,30000000	20,30000000	0,00e+00	1e-6
<code>percentil(total, 90)</code>	33,36000000	33,36000000	0,00e+00	1e-6
<code>assimetria(total)</code>	3,09616757	3,09616757	1,87e-13	1e-9
<code>covariancia(distancia, tarifa)</code>	40,73530513	40,73530513	9,24e-14	1e-9
<code>correlacao(distancia, tarifa)</code>	0,92265903	0,92265903	4,77e-15	1e-9
<code>correlacao(passageiros, tarifa)</code>	0,00779948	0,00779948	2,78e-16	1e-9
<code>regressao_linear -> b1</code>	2,77910675	2,77910675	6,22e-15	1e-9
<code>regressao_linear -> b0</code>	4,67376529	4,67376529	2,31e-14	1e-9
<code>regressao_linear -> R²</code>	0,85129968	0,85129968	9,99e-16	1e-9
<code>erro_padrao_estimativa(dist, tarifa)</code>	4,44719955	4,44719955	1,15e-14	1e-9
<code>densidade_normal(20; media; desvio)</code>	0,02873932	0,02873932	0,00e+00	1e-10
<code>densidade_exponencial(5; 1/media)</code>	0,06333750	0,06333750	1,39e-17	1e-10
<code>probabilidade_poisson(1; lambda)</code>	0,33017535	0,33017535	0,00e+00	1e-10
<code>probabilidade_binomial(3; 10; 0,3)</code>	0,26682793	0,26682793	3,89e-16	1e-10

Maior diferença absoluta observada: 4,09e-12. Somas de ponto flutuante feitas em ordens diferentes divergem nas últimas casas decimais — isso é esperado, não é bug.

Sobre as tolerâncias

1e-9 para as medidas construídas por somatório: folgado o bastante para o ruído de arredondamento e apertado o bastante para pegar erro real de fórmula — trocar $n-1$ por n produz erro da ordem de $1/n \approx 1,6 \times 10^{-4}$, cem milhões de vezes maior que a tolerância. **1e-6** para percentis, que envolvem multiplicação e divisão de índices, com folga extra por haver várias convenções possíveis. **1e-10** para as densidades teóricas, que são avaliações diretas de exp/log e saem praticamente exatas.

3.3 A suíte de testes

pytest -v roda **104 testes**: 94 do núcleo (cada função contra sua referência, mais os casos de borda — lista vazia, $n = 1$ na variância amostral, variável constante na correlação, vetores de tamanhos diferentes, p fora de $[0, 100]$ — e as identidades de consistência: $R^2 = r^2$ na regressão simples, soma das probabilidades da Binomial igual a 1, área do histograma em densidade igual a 1) e 10 da interface, em que o AppTest do Streamlit sobe a aplicação em memória, navega pelos sete módulos e verifica que nenhum levanta exceção.

Um desses testes merece destaque: ele **lê o código-fonte** de `minhastats.py` e falha se encontrar `import numpy`, `import scipy`, `import statistics` ou `import pandas`. A regra de ouro deixou de ser uma promessa e virou um teste. Um auditor adicional, `verificar_regra_de_ouro.py`, varre `app.py` e `graficos.py` procurando chamadas como `np.mean` ou `.describe()` fora do painel de validação do Módulo 1 — a única exceção, delimitada no código por marcadores explícitos.

Um bug real que os testes pegaram. A primeira versão de `tabela_frequencias_continua` calculava o limite superior da última classe como *mínimo* + $k \times \text{largura}$. Por acúmulo de erro de ponto flutuante esse valor ficava uma fração abaixo do máximo observado, e **o maior valor do conjunto caía fora da tabela** — 499 elementos contados em vez de 500. O teste que exigia “soma das frequências = n ” quebrou, e a correção foi fixar a última fronteira no próprio máximo. Sem o teste, o histograma estaria errado em um elemento e ninguém perceberia.

4. Módulo 2 — Estatística descritiva

O usuário escolhe qualquer variável e recebe as três famílias de medidas, um percentil personalizado por slider, a tabela de frequências em classes de Sturges, histograma, boxplot com os outliers do IQR destacados e a interpretação textual automática.

<<

Deploy

Laboratório Estatístico

Táxis de Nova York · março de 2019 · dados da NYC Taxi & Limousine Commission

Módulos:

☐ Módulo 0 — Os dados reais

☐ Módulo 1 — Núcleo estatístico

☒ Módulo 2 — Estatística descritiva

☐ Módulo 3 — Simulação: LGN e TCL

☐ Módulo 4 — Distribuições teóricas

☐ Módulo 5 — Correlação e regressão

☐ Módulo 6 — As três descobertas

Corridas analisadas

6.427

Variáveis numéricas

7

Variáveis categóricas

6

Regra de ouro: todas as medidas desta tela são calculadas por `minhastats.py`, escrito do zero. NumPy e SciPy só aparecem no painel de

Laboratório Estatístico Interativo

Matemática e Estatística para Computação · Sistematização · dataset: corridas de táxi de Nova York (NYC TLC)

Módulo 2 — Estatística descritiva interativa

Tipo de variável:

☒ Numérica ☐ Categórica

Escolha a variável:

Distância (milhas)

Medidas de tendência central

n	Média	Mediana	Moda
6.427	3,03	1,65	0,80

Medidas de dispersão

Amplitude	Variância (amostral)	Desvio padrão (amostral)	Coef. de variação
36,70	14,66	3,83	126,46 %

Variância populacional: 14,66 · Desvio populacional: 3,83. A amostral divide por $n - 1$ (correção de Bessel); a populacional, por n .

Medidas de posição e outliers

Q1 (25%)	Q2 (mediana)	Q3 (75%)	IQR
0,99	1,65	3,21	2,22

Percentil personalizado:

90

A aplicação em funcionamento: Módulo 2, variável Distância.

Variável	Média	Mediana	Desvio	CV	Q ₁	Q ₃	g ₁	Outliers (IQR)
Distância (mi)	3,027	1,650	3,829	126,5 %	0,990	3,210	3,007	736 (11,45%)
Tarifa (US\$)	13,087	9,500	11,532	88,1%	6,500	15,000	3,217	591 (9,20%)
Gorjeta (US\$)	1,981	1,700	2,449	123,6 %	0,000	2,800	2,664	280 (4,36%)
Pedágios (US\$)	0,326	0,000	1,416	434,9 %	0,000	0,000	5,071	350 (5,45%)
Total (US\$)	18,519	14,160	13,802	74,5%	10,800	20,300	3,096	599 (9,32%)
Passageiros	1,540	1,000	1,204	78,2%	1,000	2,000	2,357	540 (8,40%)
Duração (min)	14,363	10,917	11,641	81,0%	6,517	18,533	2,004	358 (5,57%)

Duas coisas a notar nesta tabela. Primeiro, **todas as sete variáveis têm $g_1 > 0$** — não há uma única variável simétrica no dataset, o que faz sentido: preço, tempo e distância são grandezas com piso em zero e sem teto. Segundo, **o CV dos pedágios é 434,9%**, absurdamente alto, e o motivo é que a variável é quase toda zero: 75% das corridas não pagam pedágio

Laboratório Estatístico Interativo — Sistematização

8

nenhum, então o IQR é **zero** e a regra de Tukey degenera — ela passa a marcar como “outlier” qualquer corrida que simplesmente tenha pago pedágio. A aplicação detecta esse caso e exibe um aviso em vez de apresentar o número como se fosse anomalia. É um limite do método, não um achado sobre os dados.




Figura 1 — Histograma do valor total, com classes de Sturges e as posições de média e mediana.

Leitura. O valor total pago tem média US\$ 18,52 e mediana US\$ 14,16, e o coeficiente de assimetria vale $g_1 = 3,10$ — cauda longa à direita, exatamente o que o histograma mostra. A média está sendo puxada por uma minoria de corridas caras, então **para descrever a corrida típica a mediana é a medida honesta**.

A regra da interpretação automática — e por que trocamos a primeira. Nossa primeira versão usava a regra intuitiva: “se média – mediana passar de meio desvio padrão, é assimétrica”. Ao rodá-la sobre o dataset descobrimos que ela **classificava as sete variáveis como simétricas** — inclusive os pedágios, com $g_1 = 5,07$. O motivo é uma armadilha bonita: em distribuição de cauda pesada, a própria cauda **infla o desvio padrão**, de modo que “meio desvio” vira um limiar enorme e nada o ultrapassa. A régua cresce junto com o que ela deveria medir. Trocamos o critério por $|g_1|$ ($< 0,5$ simétrica; < 1 moderada; ≥ 1 forte), que é invariante de escala. O texto continua *reportando* média $\times$ mediana, que é a leitura intuitiva, mas quem decide é g_1 .




Figura 2 — Boxplot do valor total com as cercas de Tukey e os outliers destacados.

Leitura. Com $Q_1 = 10,80$ e $Q_3 = 20,30$, o IQR é 9,50 e a cerca superior cai em US\$ 34,55. Acima dela há **599 corridas (9,32%)**. São elas que a descoberta 3 identifica.




Figura 3 — Distribuição das corridas por distrito de embarque (variável categórica).

Para variáveis categóricas a tela mostra tabela de frequências com acumuladas e barras — ou pizza, quando há até cinco categorias; acima disso a pizza é omitida com justificativa em tela. Manhattan concentra **81,97%** dos embarques, Queens 10,22%, Brooklyn 5,93% e Bronx 1,54%.

5. Módulo 3 — Simulação de Monte Carlo

5.1 Lei dos Grandes Números




Figura 4 — Convergência da frequência relativa para a probabilidade teórica, em escala logarítmica.

Após n lançamentos	10	100	1.000	5.000	Teórica
Frequência relativa de cara	0,2000	0,4400	0,5140	0,5060	0,5000

Erro final de 0,0060. O eixo x está em escala logarítmica de propósito: a convergência acontece por ordens de grandeza, e em escala linear os primeiros 50 lançamentos — justamente onde está a instabilidade interessante — ficariam espremidos contra a origem. **A leitura importante é que a convergência não é uma descida suave do erro: é uma oscilação que vai perdendo amplitude.** Mudando a semente, cada simulação zigue-zagueia diferente no começo — e todas terminam no mesmo lugar.

5.2 Teorema Central do Limite




Figura 5 — Distribuição das médias amostrais do valor total, para três tamanhos de amostra, com a Normal ajustada sobreposta.

n (tamanho da amostra)	Média das médias	Desvio observado	$\sigma/\sqrt{n}$ previsto	g_1 das médias
2	18,585	10,188	9,759	2,549
10	18,446	4,311	4,364	1,003
30	18,616	2,576	2,520	0,566

Sorteamos 2.000 amostras do valor total pago — uma população fortemente assimétrica ($g_1 = 3,096$; $\mu = 18,52$; $\sigma = 13,80$) — e histogramamos as médias, cada uma calculada pela nossa `ms.media`.

Três leituras. (1) A média das médias fica colada em $\mu = 18,519$ para qualquer n — a média amostral é um estimador **não viesado**. (2) O desvio observado acompanha $\sigma/\sqrt{n}$ com erro abaixo de 5%: quadruplicar a amostra corta o erro pela metade. (3) A assimetria das médias **cai de 2,55 para 0,57** conforme n vai de 2 a 30 — é literalmente a distribuição virando um sino, partindo de dados que são tudo menos normais. É por isso que a Normal aparece em todo lugar: não porque os fenômenos sejam normais, mas porque **médias** de qualquer coisa tendem a ser.

6. Módulo 4 — Distribuições teóricas

Os parâmetros são estimados **a partir dos próprios dados**, com as nossas funções: $\hat{\mu} = \bar{x} = 3,027$ e $\hat{\sigma} = s = 3,829$ para a Normal; $\hat{\lambda} = 1/\bar{x} = 0,3303$ para a Exponencial. O histograma está em **densidade** (área = 1) — sem isso as escalas não bateriam e as curvas sumiriam rente ao eixo.




Figura 6 — Distância das corridas com as duas curvas teóricas estimadas dos dados.

Distribuição	Erro médio absoluto de densidade	Maior erro em uma classe
Normal($\mu = 3,03$; $\sigma = 3,83$)	0,020316	0,256939
Exponencial($\lambda = 0,3303$)	0,008986	0,142236

A Normal ajusta mal, e o motivo é identificável. A distância tem $g_1 = 3,007$, longe do zero que a Normal pressupõe. Por ser simétrica, a curva normal coloca massa de probabilidade **à esquerda de zero** — região onde a variável nem pode existir, já que não há corrida de distância negativa — e ao mesmo tempo morre cedo demais na cauda direita, onde estão as corridas longas de aeroporto. A Exponencial, que já nasce assimétrica e ancorada em zero, erra **menos da metade**: descreve bem o decaimento geral, embora subestime o pico das corridas curtíssimas. Faz sentido teórico — a Exponencial é a distribuição natural de “distância até o próximo evento”, e uma corrida urbana é aproximadamente isso.




Figura 7 — Número de passageiros: proporção observada contra a Poisson com λ estimado dos dados.

k passageiros	0	1	2	3	4	5	6
Observado	1,49%	72,69%	13,63%	3,78%	1,71%	4,31%	2,38%
Poisson($\lambda = 1,540$)	21,44%	33,02%	25,42%	13,05%	5,02%	1,55%	0,40%

Para a contagem de passageiros a candidata natural é a **Poisson**, com $\hat{\lambda} = \bar{x}$. O ajuste é **ruim, e isso é o achado**: a Poisson prevê 21% de corridas com zero passageiros (observamos 1,5%) e 33% com um passageiro (observamos 73%). **Nenhum valor de λ consertaria isso** — o problema é conceitual. A Poisson descreve eventos raros e independentes ao longo de um intervalo; o número de passageiros de um táxi não é isso. É o tamanho de um grupo social, com um pico enorme em 1 (quem anda sozinho), um teto físico em 6 lugares e um segundo pico em 5 (grupos que ocupam o carro inteiro). Um modelo que não corresponde ao fenômeno não se salva com estimativa melhor de parâmetro.

7. Módulo 5 — Correlação e regressão linear




Figura 8 — Diagrama de dispersão de tarifa contra distância, com a reta de mínimos quadrados e um ponto de predição.

Medida	Valor
Covariância	40,7353
r de Pearson	0,9227 (associação quase perfeita e positiva)
Reta de mínimos quadrados	$\hat{y} = 2,7791 \cdot x + 4,6738$
R^2	0,8513
Erro padrão da estimativa	4,4472
Faixa observada de x	[0,00 ; 36,70] milhas

Interpretação dos coeficientes. Cada milha a mais está **associada**, em média, a **US\$ 2,78 a mais** de tarifa. O intercepto $b_0 = 4,67$ é o valor previsto para uma corrida de distância zero — e aqui ele tem significado concreto, porque Nova York cobra uma **bandeirada** mais taxas fixas antes de o carro andar; US\$ 4,67 é uma estimativa plausível desse piso. O $R^2 = 0,8513$ diz que a distância explica **85,13%** da variação da tarifa; os 14,87% restantes vêm do que este modelo não vê — tempo parado no trânsito, sobretaxas de horário, tarifas fixas.

Exemplo de predição: para **5 milhas** a reta prevê **US\$ 18,57**, com margem típica de $\pm$ US\$ 4,45. A aplicação avisa em vermelho se o usuário digitar um valor fora da faixa observada: extrapolar é chute vestido de matemática, porque a reta só foi validada dentro do intervalo dos dados.




Figura 9 — Resíduos da regressão. O funil que abre com a distância indica variância crescente.

O que os resíduos denunciam. Duas coisas. Primeira, o funil que abre com a distância — corridas longas erram mais, em valor absoluto, que corridas curtas (heterocedasticidade). Segunda, e mais interessante: há uma **faixa horizontal de tarifas idênticas em US\$ 52,00** no diagrama de dispersão. São **131 corridas**, e **87,8% delas tocam um aeroporto**. Não é erro nem coincidência: é a **tarifa fixa JFK ↔ Manhattan**, uma regra tarifária da cidade que ignora o taxímetro. Naquela faixa o preço simplesmente não cresce com a distância, e nenhum ajuste de b_0 ou b_1 resolve — o que faltaria é uma variável indicadora de “corrida com tarifa fixa”, isto é, outro modelo. É o tipo de coisa que R^2 nenhum revela e que só aparece quando se olha o gráfico.

⚠ **Correlação não implica causalidade.** Um exemplo limpo dentro deste mesmo dataset: **pedágios e gorjeta** têm correlação positiva ($r = 0,414$). Ninguém dá gorjeta porque pagou pedágio. As duas sobem juntas porque acompanham um terceiro fator — corridas longas, de aeroporto, que atravessam pontes e túneis e rendem contas altas. A variável escondida é a distância; pedágio e gorjeta apenas compartilham essa causa comum. Pela mesma lógica, mesmo o $r = 0,92$ entre distância e tarifa é associação: o que *causa* o preço é a regra tarifária da cidade, que por acaso usa a distância como insumo.

8. As três descobertas

8.1 Quem paga em dinheiro nunca dá gorjeta, e o defeito é do instrumento

Afirmção. Todas as 1.810 corridas pagas em dinheiro registram gorjeta exatamente zero. Isso não mede generosidade: mede o que o taxímetro consegue enxergar.




Figura 10 — Gorjeta média por forma de pagamento.

Forma de pagamento	Corridas	Gorjeta média	Gorjeta mediana	% com gorjeta zero
credit card	4.574	US\$ 2,78	US\$ 2,20	9,9%
cash	1.810	US\$ 0,00	US\$ 0,00	100,0%
Não informado	43	US\$ 0,00	US\$ 0,00	100,0%

Por que isso importa. A leitura ingênua seria “quem paga em dinheiro é mão-fechada”. Ela está errada, e o dado que a desmonta é o **100,0%**: não é uma tendência forte, é a totalidade — e comportamento humano não produz unanimidade. O taxímetro de Nova York só registra a gorjeta quando ela passa pela maquininha; gorjeta em espécie vai direto para o motorista e nunca entra no sistema. **O zero aqui significa “não medido”, não “não pago”.**

Limite honesto. A consequência é que a gorjeta média de US\$ 1,98 calculada sobre o dataset inteiro está **subestimada por construção**: ela divide o total arrecadado em cartão por *todas* as corridas, inclusive as 1.810 em que a gorjeta existiu mas não foi vista. Qualquer conclusão sobre gorjeta neste dataset só vale **dentro do subconjunto pago com cartão** — e mesmo aí o recorte não é aleatório, porque quem escolhe pagar com cartão pode ser sistematicamente diferente de quem paga em espécie. É um erro que só aparece olhando a distribuição; a média sozinha o esconde.

8.2 O número de passageiros não explica nada do preço

Afirmção. A correlação entre número de passageiros e tarifa é $r = 0,0078$, e a regressão devolve $R^2 = 0,000061$. O número de pessoas no carro explica **0,0061%** da variação do preço.




Figura 11 — Matriz de correlação. A linha de Passageiros é a única pálida do mapa inteiro.

Variável	r com nº de passageiros	r²
Distância	+0,0091	0,000083
Tarifa	+0,0078	0,000061
Gorjeta	+0,0208	0,000431
Pedágios	−0,0030	0,000009
Total pago	+0,0157	0,000247
Duração	−0,0049	0,000024

Para efeito de comparação, na mesma matriz: distância × tarifa = 0,92; tarifa × total = 0,97; distância × duração = 0,82.

Por que isso é uma descoberta. Porque a intuição de quase todo mundo prevê o contrário. Em ônibus, avião, trem e aplicativo com categoria por capacidade, mais gente custa mais caro. Em táxi de Nova York, não: a tarifa é do **veículo**, cobrada por distância percorrida e por tempo parado, e os passageiros adicionais viajam de graça. O dado não está com defeito — a intuição é que estava. Uma correlação **ausente** onde todos jurariam que existe costuma ser mais informativa que uma correlação forte esperada.

Limite honesto. O r de Pearson mede associação **linear**. Um $r \approx 0$ não prova ausência total de relação: poderia existir um efeito não linear — por exemplo, só grupos de 5 ou 6 pessoas mudarem algo — que Pearson não captura. O que torna essa hipótese pouco plausível é a **consistência**: a ausência se repete contra as seis variáveis numéricas, com sinais alternando entre positivo e negativo, que é exatamente o padrão de ruído em torno de zero. Ainda assim,

provar ausência de relação exigiria um teste que não fizemos.

8.3 Os outliers de preço têm endereço: são as corridas de aeroporto

Afirmção. 55,8% das corridas marcadas como outliers de preço pela regra do IQR começam ou terminam em um aeroporto, contra 6,3% no dataset inteiro — concentração **8,8 vezes maior**. Os valores fora da curva não são ruído: são um segmento de mercado.




Figura 12 — Proporção de corridas com ponto em aeroporto, dentro e fora do grupo de outliers.

Grupo	n	Total mediano	% com pedágio	% tocando aeroporto
Outliers (IQR)	599	US\$ 50,06	55,3%	55,8%
Demais corridas	5.828	US\$ 13,55	0,3%	6,3%

Evidência. A regra de Tukey sobre o valor total (cerca superior em US\$ 34,55) marca 599 corridas (9,32%) como outliers. O pedágio confirma por um caminho independente: ele aparece em 55,3% dos outliers e em apenas 0,3% das demais corridas — são viagens que atravessam pontes e túneis para sair da ilha de Manhattan. E a confirmação mais visual está na Figura 8: a faixa horizontal de 131 corridas com tarifa idêntica de US\$ 52,00 é a tarifa fixa JFK ↔ Manhattan, uma regra tarifária **visível a olho nu no diagrama de dispersão**.

Por que importa. Esses 599 pontos não são erro de medição, e descartá-los como “ruído” — o reflexo automático de quem vê a palavra *outlier* — apagaria um segmento real e economicamente relevante do serviço. A conclusão prática é mais forte do que “há outliers”: **não existe uma distribuição de preço de táxi em Nova York, existem duas populações misturadas**. O trajeto urbano curto, com mediana de US\$ 13,55, e a corrida de aeroporto, com mediana de US\$ 50,06 — quase quatro vezes mais. Uma média calculada sobre a mistura não descreve nem uma nem outra.

Limite honesto. Três ressalvas. (1) “Aeroporto” aqui é a zona de embarque ou desembarque **registrada**; corridas de/para Newark aparecem pouco por ser um aeroporto fora da cidade. (2) “Outlier pela regra do IQR” é uma **convenção** — o fator 1,5 —, não uma verdade da natureza; com 3,0·IQR o recorte seria outro. (3) Os 44,2% de outliers que **não** tocam aeroporto continuam sem explicação nesta análise; provavelmente são corridas longas entre distritos, mas não testamos.

9. Limitações — o que esta análise *não* permite concluir

A parte mais fácil de um trabalho estatístico é afirmar; a mais honesta é delimitar. Oito coisas que os nossos números não autorizam:

1. Não vale para outros períodos. A amostra cobre 28/02/2019 a 31/03/2019: um mês de fim de inverno, antes da pandemia. Sazonalidade, feriados, clima e a mudança de comportamento urbano pós-2020 estão fora do alcance destes dados. Nada aqui descreve o táxi de Nova York “em geral” — descreve março de 2019.

2. Não é a população de corridas. São 6.427 corridas de um universo de milhões por mês. É uma amostra pública e **não sabemos qual processo a gerou** — se foi sorteio aleatório simples, se houve filtro por região ou por tipo de corrida. Sem isso, nenhuma extrapolação formal para a cidade inteira é defensável, e nenhum intervalo de confiança que calculássemos teria a cobertura que anuncia.

3. Nada aqui é causal. Todo o trabalho é de associação. A regressão prevê bem a tarifa a partir da distância, mas não prova que a distância *causa* o preço — o que causa o preço é a regra tarifária municipal. O exemplo de pedágio $\times$ gorjeta ($r = 0,414$) mostra como duas variáveis sobem juntas sem qualquer relação direta.

4. O zero da gorjeta é ambíguo. Conforme a descoberta 1, “gorjeta = 0” pode significar “não pagou” ou “pagou em espécie e o sistema não viu”. Isso contamina toda e qualquer conclusão sobre generosidade do passageiro, e subestima por construção as médias de gorjeta e de valor total.

5. Mantivemos dados provavelmente defeituosos. As 45 corridas com distância zero e as 96 com zero passageiros foram preservadas por não serem fisicamente impossíveis, mas quase certamente são falhas de registro. Elas puxam levemente para baixo as medidas dessas duas variáveis — o efeito é pequeno (0,7% e 1,5% das linhas), mas existe.

6. Só testamos relações lineares. O r de Pearson e a reta de mínimos quadrados não enxergam curvas, patamares ou efeitos de limiar. A própria tarifa fixa de US\$ 52,00 é a prova: é uma estrutura real nos dados que o modelo linear não consegue representar.

7. A regra do IQR tem pressupostos. Ela assume dispersão no miolo da distribuição. Em variáveis infladas de zeros, como os pedágios (75% das corridas pagam zero, $IQR = 0$), a regra degenera e classifica como “outlier” qualquer valor não nulo. A aplicação sinaliza esse caso, mas ele mostra que “outlier” é um resultado de método, não uma propriedade intrínseca do dado.

8. A validação é contra NumPy/SciPy, não contra a verdade. Se o NumPy e a nossa implementação errassem a mesma fórmula da mesma forma, os testes passariam. Isso é mitigado pelos testes de propriedade — identidades como $R^2 = r^2$, somas de probabilidade iguais a 1, área do histograma igual a 1 — e pelos casos de borda, mas não é eliminado.

10. Reprodutibilidade

O dataset está versionado no repositório e todas as simulações usam **semente fixa** (42 nas figuras deste relatório), então os números acima são reproduzíveis exatamente. As figuras deste PDF e os gráficos da aplicação saem do **mesmo módulo** `graficos.py`, alimentado pelo **mesmo** `minhastats.py`: não existem duas implementações que possam divergir. E as tabelas numéricas deste documento são lidas dos arquivos JSON gerados pelos scripts — nenhum número foi digitado à mão.

```
git clone https://github.com/Joao-G14/Laboratorio-estatistico.git
cd Laboratorio-estatistico
python -m venv .venv && .venv\Scripts\activate
pip install -r requirements.txt

pytest -v                                # 104 testes
python verificar_regra_de_ouro.py         # auditoria da regra de ouro
python gerar_figuras.py                   # refaz as figuras deste relatório
streamlit run app.py                      # a aplicação
```

Links da entrega

► **VÍDEO DE DEMONSTRAÇÃO (3-5 min)**

[PREENCHER: LINK DO VÍDEO]

Item	Link
Fonte original do dataset (NYC TLC)	https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page
Arquivo CSV utilizado	https://raw.githubusercontent.com/mwaskom/seaborn-data/master/taxis.csv
Repositório público (código, testes e relatório)	https://github.com/Joao-G14/Laboratorio-estatistico

Integrante(s)

João Gabriel Amaral de Sales — matrícula 72650411